

AI Engineer – Data Scientist NLP

Solène Degrutère | soleneD05 | solene.degrutere@orange.fr | 06.48.44.42.72

Expériences professionnelles

Ingénieure IA, PraxySanté **septembre 2024 – présent**

API de résumé et d'extraction médicale

- Maintenir, améliorer et déployer une **API fastAPI multi-pipeline** en production : résumé, extraction, reformulation, classification de document
- **Déployer et mettre en production sur serveur**
- Mettre en place des **tests automatisés**

Pré-annotation NER de documents médicaux par LLM

- Développer un **workflow LLM** avec **LangGraph** et **LangChain**

Classification et extraction d'information à partir de documents médicaux

- Mettre en place un **pipeline complet de traitement de documents médicaux** (PDF, DOCX, TXT)
- **Benchmark comparatif** des **méthodes de classification** : mots-clés, NER, Machine Learning, LLM
- **Extraction d'informations** clés (identité, date NIR) via LLM, règles métier et expressions régulière

Fine-tuning de GLiNER/BERT sur données médicales synthétiques

- **Générer et annoter de données synthétiques**
- **Fine-tuning d'un modèle GLiNER** (NER zero-shot basé sur BERT) pour la reconnaissance d'entité
- Benchmark comparatif des performances avant/après fine-tuning

Ingénieure NLP, SNCF – Direction de la Recherche **mars 2023 – décembre 2023**

Identification des causes d'accidents du travail (AT) dans les déclarations d'accidents

- Etablir un **état de l'art** sur la notion de cause d'accident et sur la déclaration d'AT
- **Analyser linguistiquement** des rapports d'accidents et définition d'une méthodologie d'extraction automatique des causes
- Mettre en place et évaluer des **méthodes de classification automatique** des rapports : tests de plusieurs approches (ML, topic modeling, clustering)

Formations

Formation Data et IA Engineer – Cheffe de projet en Intelligence Artificielle

Simplon **2024 - 2025**

- Programmation python (POO, package), SQL, MongoDB
- Machine Learning & Deep Learning (LLM, Chatbot; série temporelle)
- Data visualisation : Matplotlib, Seaborn, Plotly
- Gestion de projet IA : méthodologie agile, design thinking, budget et planning
- Introduction à Docker

Master Linguistique, Informatique et Technologie du Langage

Université de Toulouse Jean Jaurès **2021 - 2023**

- Traitement Automatique du Langage (TAL) : NER, extraction d'information, apprentissage automatique
- Programmation (Python, XML, R), UX et ergonomie, gestion de projet agile
- Linguistique appliquée : syntaxe expérimentale, cohérence du discours

Licence de Sciences du Langage, de l'Information et de la Communication

Université de Limoges **2018 - 2021**

- Informatique : manipulation de fichiers XML/HTML, initiation au codage
- Linguistique théorique et appliquée : sémantique, syntaxe, rhétorique

Projet de formation

FROODIES : Application IA de recommandation personnalisée de restaurants parisiens **2024 - 2025**

- Créer une **application web interactive avec Streamlit**, intégrant une interface utilisateur
- Mettre en œuvre une démarche **Design Thinking** avec élaboration d'un plan de projet complet
- Générer un **jeu de données synthétiques** de restaurants parisiens
- Développer un **système de recommandation** basé sur la similarité des restaurants
- Intégrer un **chatbot conversationnel intelligent**

Compétences

Programmation et outils

- Python (Pandas, Numpy, Scikit-learn, NLTK, Spacy, Pytorch), R
- Base de données : SQL, MongoDB, formats structurés (CSV, JSON, XML)
- Outils : Jupyter Notebook, GitHub, uv/Poetry, Docker, DBT, Figma
- Parsing de document et web scraping : pdfplumber, pypdf, PaddleOCR, BeautifulSoup

API et frameworks

- Streamlit, FastAPI, pydantic
- Déploiement : Gunicorn, Uvicorn, Scaleway, jobs asynchrones (Valkey)
- Tests automatisés (pytest), maintenance d'API en production

IA générative et LLM

- RAG, embeddings
- Orchestration multi-LLM en production : Mistral, Qwen, Llama (Scaleway, Fireworks, Replicate)
- OpenAI API, Mistral API, prompt engineering

Traitement de données / NLP et Machine Learning

- NLP / TAL : extraction d'information, NER, classification, topic modeling, détection de négation, fuzzy matching
- Machine Learning : régression linéaire et logistique, arbres de décision, Random Forest, gradient boosting (XGBoost), SVM, k-NN, Naive Bayes, k-means
- Fine-tuning et Deep Learning : Hugging Face (Transformers), PyTorch, BERT, GLiNER, Optuna
- Évaluation de modèles : validation croisée, métriques (précision, rappel, F1), benchmarks comparatifs
- Données : campagnes d'annotation (Label Studio), génération de données synthétiques
- Terminologies médicales : CIM-10, CIM-11, SNOMED

Gestion de projet & analyse

- Méthodes agiles et Design Thinking
- Planification, prévision budgétaire, structuration de projet
- Rédaction de rapports scientifiques et analyses de données

Savoir-être

- Esprit d'équipe · Bon relationnel · Curiosité et envie d'apprendre · Rigueur et autonomie · Communication écrite professionnelle (FR/EN)

Langues

- Français : langue maternelle · Anglais : niveau intermédiaire (B2 : lecture et rédaction technique)

Centres d'intérêts

Théâtre (10 ans de pratique, spectatrice assidue) · Course à pied (préparation semi-marathon 2027) · Cuisine · Engagement local et associatif

Publication

Blivet A., **Degrutère S.**, Gendron B., Renault A., Siouffi C., Gaudray Bouju V., Cerisara C., Flamein H., Guibon G., Labeau M., et al. (2023). Participation de l'équipe TTGV à DEFT 2023 : Réponse automatique à des QCM issus d'examens en pharmacie. *CORIA-TALN / RECITAL 2023*, Paris, France. pp. 23–38. hal-04131585